



Instituto Politécnico Nacional
Escuela Superior de Cómputo

Cambios en movilidad, seguridad y actividad económica de la Ciudad de México antes, durante y después del COVID-19

Proyecto de minería de datos — Fase 1: recolección y limpieza de datos

Garcia Martinez Angel Yahel
Soto Peña Israel

Materia: Minería de Datos

2 de octubre de 2026

Resumen

Este documento reúne el trabajo de la primera fase del proyecto: la definición del problema, la identificación de fuentes de datos abiertos, su recolección y los criterios y resultados de su limpieza. El objetivo de la fase es construir una base de datos integrada, limpia y documentada sobre movilidad, seguridad y actividad económica en la Ciudad de México para el periodo 2016–2026. Esa base será el insumo de un modelo predictivo en la fase siguiente.

Índice

1. Definición del problema	5
1.1. Pregunta de investigación	5
1.2. Planteamiento	5
1.3. Qué se analizará	5
1.4. Objetivo de la fase	6
1.5. Periodos de análisis	6
1.6. Unidades de análisis	6
1.7. Variables objetivo candidatas (fase predictiva)	6
1.8. Hipótesis de trabajo	6
1.9. Alcance y limitaciones	7
2. Fuentes de información	7
2.1. Selección final	7
2.2. Primera selección	8
2.3. Movilidad	8
2.4. Seguridad	9
2.5. Actividad económica	9
2.6. Pandemia (variables de control)	10
2.7. Verificación en el portal de la CDMX	10
2.8. Referencias territoriales y de población	11
3. Metodología de recolección y limpieza	11
3.1. Organización del proyecto	11
3.2. Criterios de limpieza	11
3.3. Integración	12
4. Exploración inicial: afluencia del Metro	12
4.1. Descripción del archivo	12
4.2. Problemas de calidad detectados	13
4.3. Comportamiento de la serie	13
4.4. Caída y recuperación respecto a 2019	13
5. Recolección de datos	14
5.1. Procedimiento	14
5.2. Cobertura real de los datos	15
5.3. Problemas encontrados y decisiones	16
6. Limpieza de datos	16
6.1. Catálogos comunes	17
6.2. Carpetas de investigación (FGJ)	17
6.3. Afluencia del Metrobús	18
6.4. Puestos de trabajo asegurados (IMSS)	19
6.5. Ocupación hotelera	20
6.6. Hechos de tránsito	21
6.7. Afluencia del Metro	23
6.8. Casos positivos de COVID-19	25
6.9. Semáforo epidemiológico	26

7. Plan de trabajo y actividades pendientes	27
7.1. Preparación	27
7.2. Descarga (14 conjuntos seleccionados)	28
7.3. Tareas surgidas en la descarga	28
7.4. Exploración	29
7.5. Limpieza (selección final)	29
7.6. Integración y entrega	29
A. Enlaces a las fuentes	29

Índice de figuras

1.	Afluencia mensual del Metro de la CDMX, 2010–2026	14
2.	Carpetas mensuales por grupo de delito	18
3.	Metro frente a Metrobús, índice 2019 = 100	19
4.	Puestos de trabajo formales en las cinco subdelegaciones del IMSS con más empleo en 2019.	21
5.	Distribución de los puestos de trabajo por rango salarial en UMA, CDMX.	22
6.	Salario diario promedio (pesos corrientes) por subdelegación y promedio de la CDMX.	23
7.	Ocupación hotelera mensual en la CDMX	23
8.	Hechos de tránsito mensuales por tipo	24
9.	Atropellados y caídas de ciclista por mes	25
10.	Atropellados por alcaldía, índice 2019 = 100	26
11.	Personas fallecidas en hechos de tránsito por año y tipo de accidente.	27
12.	Afluencia del Metro, completo y sin las Líneas 1 y 12	27
13.	Afluencia diaria promedio por línea y año, índice 2019 = 100.	28
14.	Estaciones del Metro cerradas por día	29
15.	Casos positivos de COVID-19 por semana y tasa de positividad (residentes de la CDMX).	30

Índice de tablas

1.	Problemas de los datos disponibles.	5
2.	Dimensiones y variables del análisis.	5
3.	Periodos propuestos. Los cortes pueden ajustarse con base en el semáforo epidemiológico de la CDMX.	6
4.	Selección final de conjuntos de datos.	7
5.	Conjuntos de datos seleccionados.	8
6.	Fuentes de movilidad.	8
6.	Fuentes de movilidad.	9
7.	Fuentes de seguridad.	9
8.	Fuentes de actividad económica.	9
8.	Fuentes de actividad económica.	10
9.	Fuentes sobre la pandemia.	10
10.	Verificación en vivo de los conjuntos del portal de la CDMX (consulta del 26/09/2026).	10
10.	Verificación en vivo de los conjuntos del portal de la CDMX (consulta del 26/09/2026).	11
11.	Perfil de las columnas del archivo del Metro.	12
12.	Ejemplos de nombres de estación reparados.	13
13.	Índice promedio anual de afluencia del Metro (2019 = 100). *2026: enero a julio.	14
14.	Afluencia anual por línea (millones de viajes), con los nombres de línea ya normalizados.	15
15.	Cobertura real de los conjuntos descargados.	15
15.	Cobertura real de los conjuntos descargados.	16
16.	Pasos de limpieza de las carpetas de la FGJ.	17
17.	Pasos de limpieza del Metrobús.	18
18.	Puestos de trabajo formales en la CDMX (IMSS).	20
19.	Hechos de tránsito por año (164,706 accidentes).	22
20.	Errores encontrados en la limpieza del Metro.	24
21.	Errores encontrados en la limpieza de los casos COVID.	28

1. Definición del problema

1.1. Pregunta de investigación

¿Cómo cambiaron los patrones de movilidad, seguridad y actividad económica de la Ciudad de México durante la pandemia de COVID-19, y qué diferencias se observan en su recuperación posterior respecto al periodo previo a 2020?

1.2. Planteamiento

La pandemia de COVID-19 provocó un choque abrupto sobre la vida urbana de la Ciudad de México (CDMX). En México, el primer caso se confirmó el 28 de febrero de 2020 y la Jornada Nacional de Sana Distancia comenzó el 23 de marzo de 2020.

Los datos para medir este choque existen, pero están **dispersos** entre distintas instituciones: Gobierno de la CDMX, Fiscalía General de Justicia (FGJ), Secretaría de Seguridad Ciudadana (SSC), C5, INEGI, IMSS y Secretaría de Salud. Además, tienen **granularidades distintas**. En el tiempo pueden ser diarios, mensuales o trimestrales. En el territorio pueden estar por estación, colonia, alcaldía o entidad. Sus formatos y calidades también varían. No existe una base integrada que permita comparar las tres dimensiones sobre un mismo eje temporal y territorial.

Tabla 1: Problemas de los datos disponibles.

Problema	Ejemplo
Dispersión	Gobierno CDMX, FGJ, SSC, C5, INEGI, IMSS y Secretaría de Salud publican cada uno por separado.
Granularidad distinta	Metro: diario por estación. Carpetas de la FGJ: por evento, con coordenadas. ITAEE: trimestral por entidad.
Calidad heterogénea	Texto mal codificado, cambios de catálogo (PGJ → FGJ), cierres de líneas del Metro y series que empiezan en 2020.

1.3. Qué se analizará

El análisis cubre tres dimensiones de la vida urbana, más una dimensión de control que mide la intensidad de la pandemia (Tabla 2).

Tabla 2: Dimensiones y variables del análisis.

Dimensión	Qué se mide	Variables principales
Movilidad	Uso del transporte público y privado	Afluencia de Metro, Metrobús, STE, RTP y Ecobici; tránsito vehicular; hechos de tránsito
Seguridad	Delitos denunciados, emergencias y percepción	Carpetas de investigación por tipo de delito, víctimas, llamadas al 911, percepción de inseguridad (ENSU)
Actividad económica	Empleo y actividad productiva	Asegurados en el IMSS, ocupación y desocupación (ENOE), ITAEE, unidades económicas (DENUE), ocupación hotelera
Pandemia (control)	Intensidad del COVID-19	Casos, positividad, hospitalización, color del semáforo

1.4. Objetivo de la fase

El problema a resolver en esta fase es **construir un conjunto de datos integrado, limpio y documentado** que permita:

1. Medir la magnitud de la caída de cada dimensión en 2020.
2. Medir la velocidad y el nivel de recuperación: si se volvió a la línea base, cuándo, o si se llegó a un nuevo equilibrio.
3. Relacionar las dimensiones entre sí y con la intensidad de la pandemia (casos, semáforo epidemiológico).
4. Servir de insumo a un modelo predictivo en la fase siguiente.

1.5. Periodos de análisis

Tabla 3: Periodos propuestos. Los cortes pueden ajustarse con base en el semáforo epidemiológico de la CDMX.

Periodo	Rango	Uso
Pre-pandemia (línea base)	2016-01-01 – 2020-02-29	Tendencia y estacionalidad «normal»
Confinamiento / choque	2020-03-01 – 2021-06-30	Caída; semáforo rojo/naranja
Transición	2021-07-01 – 2022-12-31	Reapertura gradual, vacunación
Post-pandemia	2023-01-01 – último dato	Recuperación / «nueva normalidad»

1.6. Unidades de análisis

- **Temporal:** diaria donde exista. La base integrada se agregará a nivel **semanal y mensual**.
- **Territorial:** la unidad común es la **alcaldía** (16). Se usará colonia o estación solo cuando el dato lo permita.

1.7. Variables objetivo candidatas (fase predictiva)

- Afluencia mensual total en transporte público (Metro + Metrobús + STE + RTP).
- Delitos de alto impacto por alcaldía y mes.
- Empleo formal (trabajadores asegurados en el IMSS) en la CDMX por mes.
- Índice de recuperación: el valor observado entre el valor esperado sin pandemia. El valor esperado es un contrafactual estimado con la tendencia anterior a 2020.

1.8. Hipótesis de trabajo

H1. La movilidad en transporte masivo cayó más del 50 % en abril–mayo de 2020 y no se recuperó al mismo ritmo que el tránsito vehicular.

H2. Los delitos patrimoniales en vía pública (robo a transeúnte y en transporte) cayeron junto con la movilidad. La violencia familiar no disminuyó, o incluso aumentó.

H3. El empleo formal se recuperó antes que la movilidad en transporte público, por el efecto del teletrabajo.

H4. La recuperación fue desigual entre alcaldías centrales y periféricas. Con la selección final (Sección 2.1) solo se evalúa en seguridad y seguridad vial.

1.9. Alcance y limitaciones

- El modelado, la inferencia causal y los pronósticos quedan fuera de esta fase.
- Las carpetas de investigación miden *denuncias*, no delitos ocurridos. Según la ENVIPE, la cifra negra ronda el 90 %. Por eso se complementan con las llamadas al 911 y con las encuestas ENVIPE y ENSU.
- Algunas series creadas durante la pandemia (Google Mobility, índices de movilidad de la CDMX) **no tienen línea base anterior a 2020**. Sirven para describir el periodo pandémico, pero no para comparar antes y después.
- Hubo cambios metodológicos. Por ejemplo, la PGJ se transformó en FGJ y algunos delitos se reclasificaron. Estos cambios deben documentarse al unir las series.

2. Fuentes de información

La mayoría de las fuentes provienen del Portal de Datos Abiertos de la CDMX (<https://datos.cdmx.gob.mx>). Este portal usa la plataforma CKAN, cuya API permite consultar el catálogo de forma automática. El resto de las fuentes provienen de INEGI, IMSS, SESNSP y la Secretaría de Salud.

2.1. Selección final

Después de descargar y revisar los datos, la selección se redujo a **ocho conjuntos**: seis principales y dos de control (Tabla 4). Los hechos de tránsito se prefirieron sobre Ecobici porque complementan las debilidades del Metro: miden el tránsito vehicular, que es la otra mitad de la hipótesis H1, y tienen datos por alcaldía.

Tabla 4: Selección final de conjuntos de datos.

Dimensión	Conjunto	Rol
Movilidad	Metro	Principal: transporte masivo
Movilidad	Metrobús	Principal: transporte masivo
Movilidad	Hechos de tránsito (SSC)	Principal: tránsito vehicular, por alcaldía
Seguridad	Carpetas de investigación (FGJ)	Principal: delitos por tipo y alcaldía
Economía	Puestos de trabajo (IMSS)	Principal: empleo formal y salario
Economía	Ocupación hotelera	Principal: turismo y servicios
Pandemia	Casos COVID CDMX	Control: intensidad de la pandemia
Pandemia	Semáforo epidemiológico	Control: restricciones vigentes

Descartados. Se descartaron cinco conjuntos:

- **Ecobici:** termina en julio de 2024 y cambió de sistema en 2022.
- **Llamadas al 911:** no llega al periodo post-pandemia y es el más costoso de limpiar.
- **ENOE:** son microdatos nacionales y el IMSS ya cubre el empleo.
- **SESNSP:** solo servía para validar a la FGJ y requería descarga manual.
- **DENUE.**

Sus archivos se conservan en `data/raw/`. En consecuencia, la hipótesis H4 (diferencias entre alcaldías) solo se evaluará en seguridad y seguridad vial, y el ejemplo de imputación con regresión será el *backcasting* de la ocupación hotelera con el empleo del IMSS.

2.2. Primera selección

Se identificaron 29 fuentes en total. Para que la fase sea manejable sin perder cobertura, se seleccionaron 14 con cuatro criterios:

1. Tener datos anteriores a 2020, para contar con una línea base.
2. Llegar hasta 2024–2025, para observar la recuperación.
3. Ser mensuales o más finos, de preferencia por alcaldía.
4. Poder descargarse sin registro.

Las demás fuentes quedan como opcionales. Las tablas de las secciones siguientes conservan el inventario completo.

Tabla 5: Conjuntos de datos seleccionados.

#	Dimensión	Conjunto de datos	Granularidad	Desde
1	Movilidad	Afluencia diaria del Metro	día × estación	2010
2	Movilidad	Afluencia diaria de Metrobús	día × línea	2005
3	Movilidad	Viajes Ecobici	día/hora × género × edad	2010
4	Movilidad	Hechos de tránsito SSC (serie comparable)	evento × alcaldía	por revisar
5	Seguridad	Carpetas de investigación FGJ	evento georreferenciado	2016
6	Seguridad	Llamadas al 911 (C5)	llamada × alcaldía	2019
7	Seguridad	Incidencia delictiva municipal (SESNSP)	mes × municipio	2015
8	Economía	Puestos de trabajo asegurados (IMSS)	mes × municipio × sector	1997
9	Economía	ENOE (INEGI)	trimestre × entidad	2005
10	Economía	DENUE (cortes anuales)	establecimiento	2019
11	Economía	Ocupación hotelera	mes	2018-10
12	Pandemia	Casos, pruebas y positividad CDMX	día	2020-03
13	Pandemia	Semáforo epidemiológico (por construir)	semana	2020-06
14	Referencia	Población (Censo 2020) y Marco Geoestadístico	alcaldía	—

Opcionales: STE, RTP, afluencia preliminar, movilidad histórico COVID-19, GTFS, Google Mobility, víctimas FGJ, ENSU, ENVIPE, ITAEE (requiere token de INEGI), directorio de unidades económicas, seguro de desempleo, Monitor Estadístico, SINAVE, casos por colonia y capacidad hospitalaria.

Estado: ✓ = existencia verificada en el catálogo el 26/09/2026; ○ = pendiente de verificar. Los enlaces completos están en el Apéndice A.

2.3. Movilidad

Tabla 6: Fuentes de movilidad.

Conjunto de datos	Institución	Granularidad	Cobertura	Est.
Afluencia diaria del Metro (simple y desglosada)	STC Metro	Día × estación × línea	2010-01 – 2026-07	✓
Afluencia diaria de Metrobús	Metrobús	Día × línea	por revisar	✓

Tabla 6: Fuentes de movilidad.

Conjunto de datos	Institución	Granularidad	Cobertura	Est.
Afluencia diaria STE (Trolebús, Tren Ligero, Cablebús)	STE	Día × línea	por revisar	✓
Afluencia diaria RTP	RTP	Día × ruta	por revisar	✓
Afluencia preliminar en transporte público (histórico)	SEMOVI	Día × sistema	por revisar	✓
Viajes del sistema Ecobici	Ecobici	Viaje individual	cambio de sistema en 2022	✓
Datos de movilidad (histórico COVID-19)	Gobierno CDMX	Día / semana	2020 – ~2022	✓
Hechos de tránsito SSC (serie comparable)	SSC	Evento	por revisar	✓
Google COVID-19 Community Mobility Reports	Google	Día × entidad	2020-02 – 2022-10	○
GTFS estático de la CDMX	SEMOVI	Estático (rutas, estaciones)	—	✓

2.4. Seguridad

Tabla 7: Fuentes de seguridad.

Conjunto de datos	Institución	Granularidad	Cobertura	Est.
Carpetas de investigación FGJ (CSV anuales y acumulado)	FGJ CDMX	Evento con coordenadas, colonia, alcaldía	2016 – 2024+	✓
Víctimas en carpetas de investigación	FGJ CDMX	Víctima (sexo, edad)	2019 –	✓
Llamadas al 911 (archivos semestrales)	C5 CDMX	Llamada × incidente × alcaldía	2019-S1 – 2022+	✓
Incidencia delictiva del fuero común (municipal)	SESNSP	Mes × municipio × delito	2015 –	○
ENSU: percepción de inseguridad	INEGI	Trimestre × ciudad	2013 –	○
ENVIPE: victimización y cifra negra	INEGI	Anual × entidad	2011 –	○

2.5. Actividad económica

Tabla 8: Fuentes de actividad económica.

Conjunto de datos	Institución	Granularidad	Cobertura	Est.
Puestos de trabajo asegurados	IMSS	Mes × municipio × sector	1997 –	○
ENOE / ETOE (ocupación, desocupación, informalidad)	INEGI	Trimestre × entidad	2005 –	○
ITAE (actividad económica estatal)	INEGI (BIE)	Trimestre × entidad × sector	2003 –	○

Tabla 8: Fuentes de actividad económica.

Conjunto de datos	Institución	Granularidad	Cobertura	Est.
DENUE (cortes anuales)	INEGI	Establecimiento con coordenadas	2019 –	○
Directorio estadístico de unidades económicas	Portal CDMX	Establecimiento	por revisar	✓
Solicitudes al Seguro de Desempleo	STyFE	por revisar	por revisar	✓
Ocupación hotelera	SECTUR CDMX	Mes	por revisar	✓
Indicadores del Monitor Estadístico de la CDMX	Gobierno CDMX	por revisar	por revisar	✓

2.6. Pandemia (variables de control)

Tabla 9: Fuentes sobre la pandemia.

Conjunto de datos	Institución	Granularidad / nota	Est.
Casos positivos, pruebas y positividad	Portal CDMX	Día	✓
Base SINAVE COVID-19	SINAVE	Caso individual	✓
Histórico de casos a nivel colonia	SINAVE / CDMX	Colonia	✓
Capacidad hospitalaria ZMVM	Portal CDMX	Día × hospital	✓
Semáforo epidemiológico de la CDMX	Gobierno CDMX	Semana; no hay dataset, se construirá a partir de los comunicados	○
Datos abiertos COVID-19 nacionales	Secretaría de Salud	Caso individual	○

2.7. Verificación en el portal de la CDMX

Para confirmar que los conjuntos del portal siguen disponibles, se consultó su API CKAN (`package_show`) desde el notebook `00_contexto_y_datasets.ipynb`. La consulta devolvió, para cada conjunto, su fecha de última actualización y el número de archivos que ofrece. Los 20 conjuntos consultados existen y fueron actualizados entre el 31 de agosto y el 23 de septiembre de 2026 (Tabla 10).

Tabla 10: Verificación en vivo de los conjuntos del portal de la CDMX (consulta del 26/09/2026).

Dimensión	Conjunto de datos	Actualizado	Archivos	CSV
Movilidad	Afluencia diaria del Metro	2026-09-01	4	4
Movilidad	Afluencia diaria de Metrobús	2026-09-04	4	4
Movilidad	Afluencia diaria STE	2026-09-01	4	4
Movilidad	Afluencia diaria RTP	2026-09-04	2	2
Movilidad	Afluencia preliminar en transporte público	2026-09-01	1	1
Movilidad	Viajes Ecobici	2026-09-01	2	2
Movilidad	Movilidad histórico COVID-19	2026-09-01	10	10
Movilidad	Hechos de tránsito SSC (serie comparable)	2026-09-01	2	1
Movilidad	GTFS estático	2026-09-01	1	0
Seguridad	Carpetas de investigación FGJ	2026-08-31	13	10

Tabla 10: Verificación en vivo de los conjuntos del portal de la CDMX (consulta del 26/09/2026).

Dimensión	Conjunto de datos	Actualizado	Archivos	CSV
Seguridad	Víctimas en carpetas FGJ	2026-09-01	11	7
Seguridad	Llamadas al 911	2026-09-01	9	8
Economía	Directorio de unidades económicas CDMX	2026-09-23	5	2
Economía	Seguro de desempleo CDMX	2026-09-01	1	1
Economía	Ocupación hotelera	2026-09-01	1	1
Economía	Monitor Estadístico CDMX	2026-09-01	32	32
Pandemia	Casos, pruebas y positividad	2026-09-01	2	1
Pandemia	Base SINAVE COVID-19	2026-09-01	11	10
Pandemia	Casos por colonia	2026-09-01	1	1
Pandemia	Capacidad hospitalaria ZMVM	2026-09-01	2	2

Por ejemplo, las carpetas de investigación de la FGJ se publican en un CSV por año (2016–2024), más un archivo acumulado y tres notas metodológicas en PDF: sobre las actualizaciones, sobre las diferencias con las cifras del SESNSP y sobre las reclasificaciones de delitos. Esto permite descargar solo los años del periodo de estudio.

2.8. Referencias territoriales y de población

- **Marco Geoestadístico (INEGI):** polígonos de alcaldías, colonias y AGEB, junto con sus claves geográficas.
- **Censo de Población y Vivienda 2020 (INEGI):** población por alcaldía, que permite calcular tasas por cada 100 mil habitantes.
- **Proyecciones de población (CONAPO):** denominadores anuales.
- **Calendario de días festivos y vacaciones de la SEP:** control de la estacionalidad.

3. Metodología de recolección y limpieza

3.1. Organización del proyecto

Los datos se organizan en tres niveles. Así, los archivos originales nunca se modifican y cada transformación puede reproducirse:

Carpeta	Contenido
data/raw/	Descargas originales, sin modificar
data/interim/	Datos limpios por fuente (CSV y Parquet)
data/processed/	Base integrada (alcaldía × mes, CDMX × semana)
docs/	Diccionarios de datos y notas metodológicas
src/download/	Un script de descarga por fuente
src/clean/	Un script de limpieza por fuente
notebooks/	Análisis exploratorio
informe/	Este documento

3.2. Criterios de limpieza

Estos criterios aplican a todas las fuentes:

1. **Codificación.** Todos los archivos se convierten a UTF-8. Por ejemplo, el CSV del Metro presenta texto mal codificado (*mojibake*): *Isabel la CatÃ³lica* en lugar de «Isabel la Católica».
2. **Fechas.** Se convierten al formato ISO 8601. En las carpetas de la FGJ hay que decidir explícitamente si se usa la fecha del hecho o la fecha de inicio de la carpeta.
3. **Alcaldías.** Se crea un catálogo único con la clave INEGI (09002–09017). Se normalizan acentos, mayúsculas y nombres anteriores («Delegación»).
4. **Estaciones y líneas.** Se crea un catálogo único y se documentan los cierres prolongados: la Línea 12 desde el 3 de mayo de 2021 y la Línea 1 por su modernización desde julio de 2022.
5. **Faltantes y ceros.** Se distingue un día «sin servicio» (cierre) de un «dato faltante».
6. **Duplicados y registros fuera del dominio.** Se eliminan los duplicados y las carpetas con coordenadas fuera del polígono de la CDMX.
7. **Catálogo de delitos.** Los delitos se agrupan en categorías estables (alto impacto, patrimonial, violencia familiar, etc.) que no cambien con las reclasificaciones de la FGJ.
8. **Agregación.** Toda serie se entrega también a nivel alcaldía $\times$ mes y CDMX $\times$ semana.
9. **Trazabilidad.** De cada archivo descargado se registran la URL, la fecha de descarga y el hash SHA-256 en `data/raw/MANIFEST.csv`.

3.3. Integración

Las llaves comunes son la **fecha** (día, semana o mes) y la **clave de alcaldía**. Cada fuente limpia se agrega a esas llaves y después se unen todas. Para comparar series con escalas distintas se calculan dos indicadores:

- **Tasas por cada 100 mil habitantes**, para los delitos.
- **Índices base 100**, donde 100 es el promedio de 2019. Así se mide la caída y la recuperación en términos relativos.

4. Exploración inicial: afluencia del Metro

La afluencia del Metro es la serie de movilidad **más larga y detallada** disponible: es diaria, por estación, y cubre de 2010 a 2026. Se exploró primero para ilustrar el fenómeno que se estudiará y los problemas de calidad que habrá que limpiar. El código está en el notebook `notebooks/00_contexto_y_datasets.ipynb`.

4.1. Descripción del archivo

El recurso «Afluencia Diaria del Metro (Simple)» tiene **1,180,920 registros**, del 2010-01-01 al 2026-07-31. Cada registro corresponde a un día, una línea y una estación. No tiene valores nulos (Tabla 11).

Tabla 11: Perfil de las columnas del archivo del Metro.

Columna	Tipo	Nulos	Valores únicos
<code>fecha</code>	fecha	0	6,056
<code>anio</code>	entero	0	17
<code>mes</code>	texto	0	12
<code>linea</code>	texto	0	24
<code>estacion</code>	texto	0	168
<code>afluencia</code>	entero	0	92,564

4.2. Problemas de calidad detectados

1. Texto mal codificado (*mojibake*). El archivo se guardó con una codificación incorrecta, por lo que las letras acentuadas aparecen alteradas. Esto afecta a **57 de los 168** nombres de estación. Se reparó con la librería `ftfy`, y tras la reparación quedan **165 estaciones** únicas, porque algunas variantes eran duplicados de la misma estación (Tabla 12).

Tabla 12: Ejemplos de nombres de estación reparados.

Original	Reparado
Isabel la CatÃ³lica	Isabel la Católica
Pino SuÃ¡rez	Pino Suárez
GÃ³mez FarÃ¡as	Gómez Farías
PantitlÃ¡n	Pantitlán
DivisiÃ³n del Norte	División del Norte
FerrerÃ¡a/Arena Ciudad de MÃ©xico	Ferrería/Arena Ciudad de México

2. Nombres de línea inconsistentes. La columna `línea` tiene 24 valores distintos, pero el Metro tiene 12 líneas. Entre 2021 y 2023 el archivo escribe `LÃnea 1` (con acento y mal codificado) y en los demás años `Linea 1`. Si no se corrige, cada línea queda partida en dos series. Se normalizó a la forma `LÃnea N`.

3. Cierres de líneas. La Línea 12 cerró tras el colapso del 3 de mayo de 2021, y la Línea 1 cerró por su modernización a partir de julio de 2022. Estos cierres reducen la afluencia por causas ajenas a la demanda, así que deben marcarse para no confundirlos con una falta de recuperación (Tabla 14).

4.3. Comportamiento de la serie

La Figura 1 muestra la afluencia mensual con los periodos de análisis sombreados. Hay dos choques visibles:

- Uno **puntual**: el sismo del 19 de septiembre de 2017.
- Uno **prolongado**: la pandemia, con una caída abrupta en marzo–abril de 2020 y una recuperación lenta que todavía no está completa.

4.4. Caída y recuperación respecto a 2019

Para medir la caída y la recuperación en términos relativos se construyó un índice con base 2019 = 100:

$$I_t = \frac{\text{afluencia}_t}{\text{afluencia}_{2019}} \times 100$$

donde afluencia_{2019} es el promedio mensual de 2019.

- **Mes más bajo**: mayo de 2020, con $I = 27.0$, es decir, una **caída del 73 %** respecto a 2019. Esto respalda la hipótesis H1, que planteaba una caída mayor al 50 %.
- **Último mes disponible**: julio de 2026, con $I = 78.1$. La afluencia **aún no recupera** el nivel previo a la pandemia.




Figura 1: Afluencia mensual del Metro de la CDMX, 2010–2026, con los periodos de análisis sombreados. Fuente: elaboración propia con datos del STC Metro (Portal de Datos Abiertos de la CDMX).

Tabla 13: Índice promedio anual de afluencia del Metro (2019 = 100). *2026: enero a julio.

Año	2016	2017	2018	2019	2020	2021	2022	2023	2024	2025	2026*
Índice	104.3	101.3	103.3	100.0	56.1	49.8	64.6	69.9	73.5	78.7	77.0

Lectura preliminar. En 2025, la afluencia total equivale al 78.7 % de la de 2019. Si se excluyen las Líneas 1 y 12, afectadas por cierres, la proporción sube al 83.2 %. La Línea 1, reabierto de forma parcial, apenas llega al 51 %. Aun sin los cierres, ninguna línea ha vuelto al nivel de 2019: van del 73 % (Línea 5) al 96 % (Línea A). Esto sugiere un efecto persistente de la pandemia sobre la demanda, posiblemente por el teletrabajo (hipótesis H3). Al mismo tiempo, confirma que el análisis de recuperación debe separar el efecto de la pandemia del efecto de los cierres de infraestructura.

5. Recolección de datos

5.1. Procedimiento

La descarga se automatizó con scripts de Python en `src/download/`, uno por fuente:

Script	Qué hace
<code>comun.py</code>	Funciones compartidas: no vuelve a bajar lo que ya existe, espera 2 s entre descargas, reintenta si falla y registra cada archivo en <code>data/raw/MANIFEST.csv</code> .
<code>portal_cdmx.py</code>	Consulta la API CKAN del portal de la CDMX para obtener las URL vigentes de cada dataset y las descarga.
<code>inegi.py</code>	DENUE (cortes anuales), Censo 2020, Marco Geoestadístico y microdatos de la ENOE.
<code>imss.py</code>	Lee en <i>streaming</i> el CSV nacional mensual del IMSS y guarda solo las filas de la CDMX.
<code>semaforo.py</code>	Semáforo epidemiológico federal semanal por entidad.
<code>registrar_manual.py</code>	Registra en el MANIFEST los archivos bajados a mano desde el navegador.

Tabla 14: Afluencia anual por línea (millones de viajes), con los nombres de línea ya normalizados.

Línea	2019	2020	2021	2022	2023	2024	2025
Línea 1	237.5	137.5	128.0	108.0	63.3	67.8	120.1
Línea 2	269.1	137.7	113.5	177.1	198.8	212.2	217.0
Línea 3	222.4	124.1	107.5	164.1	172.4	172.3	175.1
Línea 4	29.0	16.1	15.9	23.4	26.5	24.9	25.1
Línea 5	78.0	44.0	44.1	56.0	59.9	59.6	56.7
Línea 6	49.9	26.1	23.5	35.7	40.0	38.8	38.8
Línea 7	108.2	55.0	51.9	69.0	78.9	85.6	88.9
Línea 8	133.6	76.4	82.7	115.6	128.2	124.6	118.2
Línea 9	99.6	59.3	62.6	87.6	95.8	80.6	94.5
Línea 12	134.9	78.2	22.1	0.0	46.0	105.0	118.6
Línea A	79.9	52.0	54.8	72.9	75.7	71.7	77.1
Línea B	152.5	87.8	87.5	120.5	129.7	128.6	125.3

Trazabilidad. El archivo `MANIFEST.csv` guarda, para cada archivo descargado, la fuente, la URL, la fecha de descarga, el tamaño y su huella SHA-256. Con eso cualquier persona puede verificar que los datos usados son exactamente los publicados.

Descargas responsables. Todas las fuentes son de datos abiertos publicados para su reutilización. Aun así, los scripts esperan entre descargas y usan caché para no repetir peticiones. La única fuente que bloquea las descargas automáticas es el SESNSP, que publica en SharePoint. Ese archivo se descarga a mano desde el navegador y después se registra en el MANIFEST.

Filtrado del IMSS. El IMSS publica un archivo nacional por mes de unos 350 MB. En lugar de guardarlo completo, el script lo lee línea por línea mientras se descarga y conserva solo las filas con `cve_entidad = 9`. El resultado ocupa unos 6 MB comprimidos por mes, frente a los 350 MB originales. La codificación de los archivos cambia entre años (Latin-1 en 2019 y UTF-8 en 2025), por lo que el filtro trabaja sobre los bytes sin decodificarlos.

5.2. Cobertura real de los datos

Al revisar lo descargado, la cobertura resultó distinta de la que anuncian los catálogos (Tabla 15).

Tabla 15: Cobertura real de los conjuntos descargados.

Conjunto	Cobertura	Registros	Observaciones
Metro (simple)	2010-01 – 2026-07	1,180,920	Texto mal codificado; nombres de línea inconsistentes
Metro (desglosada)	2021-01 – 2026-07	1,192,230	Solo desde 2021
Metrobús (simple)	2005-07 – 2026-07	53,732	Desglosada solo desde 2021
Ecobici (diaria)	2010-02 – 2024-07	12,261	Termina en julio de 2024
Hechos de tránsito (comparable)	2018 – 2019	30,758	No cubre la pandemia
Hechos de tránsito (ampliada)	2018 – 2023	134,079	No comparable entre años
Hechos de tránsito 2024	2024	30,655	Fechas en dd/mm/aaaa
Carpetas FGJ	2016-01 – 2024-07	1,987,424	2024 incompleto
Llamadas al 911	2019-S1 – 2022-S1	4,117,932	No llega al post-pandemia
Ocupación hotelera	2018-10 – 2024-07	70	16 meses de línea base

Tabla 15: Cobertura real de los conjuntos descargados.

Conjunto	Cobertura	Registros	Observaciones
Casos COVID CDMX	2020-03 – 2023-04	1,113	—
Semáforo federal	2020-W22 – 2023-W24	32 entidades	Faltaban 2020-W53 y 2022-W01 (ya rellenas)
DENUE	nov-2019 – nov-2024, vigente	7 cortes	No hay corte de nov-2025
ENOE	2016; 2018-T3 – 2026-T2	35 trimestres	Faltan 2017, 2018-T1/T2 y 2020-T2
IMSS asegurados	2016-01 – 2026-08	128 meses	Filtrado a la CDMX; sin desglose por alcaldía
SESNSP municipal	2015 – 2025	—	Descarga manual pendiente

5.3. Problemas encontrados y decisiones

1. **Hechos de tránsito.** La «serie comparable» solo cubre 2018–2019. Se agregó la serie «ampliada» (2018–2023) y la de 2024. Esta serie pasa de unos 17 mil hechos anuales en 2018–2020 a unos 30 mil en 2022–2023. El salto se debe a cambios en la forma de registro, por lo que la serie se usará con cautela, principalmente como indicador relativo. Los archivos usados están disponibles en Google Drive: https://drive.google.com/drive/folders/1_IhOf-9izLZPIRkHpHvWx10ML001kmAK.
2. **Series que terminan en julio de 2024.** Las carpetas de la FGJ, Ecobici y la ocupación hotelera dejan de actualizarse en julio de 2024. Por eso la ventana post-pandemia común a todas las fuentes es **enero de 2023 a julio de 2024**. Metro, Metrobús e IMSS permiten extender el análisis hasta 2026.
3. **Llamadas al 911.** El portal solo publica hasta el primer semestre de 2022. Además, las fechas vienen en varios formatos, y alrededor del 60 % no se interpreta con un solo formato.
4. **ENOE.** Los microdatos de 2017 y del primer semestre de 2018 no están en datos abiertos con el nombre estándar. En el segundo trimestre de 2020 la encuesta presencial se suspendió por la pandemia. De 2020-T3 a 2022-T4 se publicó como «ENOE nueva» (**enoen**).
5. **Semáforo epidemiológico.** No existe como dataset oficial descargable. Se usó la compilación del paquete de R **semaforos** (Hugo Gruson), que recopila los semáforos semanales publicados por la Secretaría de Salud. Corresponde al semáforo *federal*. El semáforo local de la CDMX a veces se adelantó: por ejemplo, el rojo se decretó el 18 de diciembre de 2020 y el federal entró el 21.
6. **IMSS sin alcaldías.** El diccionario oficial y la revisión de los 128 meses muestran que el campo `cve_municipio` viene vacío para toda la CDMX. El empleo formal solo puede analizarse para la ciudad completa, aunque con desglose por sector, sexo, edad y salario. La dimensión económica por alcaldía se cubrirá con el DENUE.
7. **Archivos duplicados.** Se descartó el acumulado de carpetas de la FGJ (560 MB) porque contiene los mismos registros que los archivos anuales.

6. Limpieza de datos

Cada fuente se limpia con su propio script en `src/clean/`. Todos leen de `data/raw/` sin modificar los originales y escriben en `data/interim/` en dos formatos: CSV, el principal, que se abre en Excel y en cualquier programa, y Parquet, un respaldo más ligero que conserva los tipos de dato. La base de carpetas de la FGJ tiene 1.9 millones de filas, más de las 1,048,576 que admite Excel, por lo que se trabaja con pandas o con su versión agregada. Cada script genera además un reporte en `docs/limpieza_<fuente>.md`, con el número de registros afectados en cada paso.

6.1. Catálogos comunes

El módulo `catalogos.py` concentra lo que comparten todas las fuentes:

- **Catálogo de alcaldías.** Las 16 alcaldías con su clave INEGI (09002 a 09017) y sus polígonos, leídos directamente del Marco Geoestadístico 2020.
- **Normalización de texto.** Repara el *mojibake*, quita acentos, pasa a mayúsculas y elimina espacios repetidos. Así «Álvaro Obregón», «ALVARO OBREGON» y su versión mal codificada se reconocen como la misma alcaldía.
- **Asignación por coordenadas.** Ubica la alcaldía de un punto (latitud, longitud) mediante una prueba de punto en polígono.

6.2. Carpetas de investigación (FGJ)

Decisiones principales.

1. **Fecha del hecho, no de inicio.** Cada archivo anual contiene las carpetas *iniciadas* ese año, que pueden referirse a hechos anteriores. Para medir cuándo ocurren los delitos se usa `fecha_hecho`. La mediana del retraso entre el hecho y la denuncia es de 1 día, pero el percentil 90 es de 56 días.
2. **Ventana 2016 – julio de 2024.** Se descartan los hechos anteriores a 2016: solo aparecen si se denunciaron desde 2016, así que su registro está incompleto. Por la misma razón, junio y julio de 2024 se marcan como *meses incompletos*, porque todavía faltan las denuncias tardías.
3. **Alcaldía.** Se toma de `alcaldia_hecho`. Coincide con la alcaldía calculada por coordenadas en el 99.7 % de los casos. Los registros «CDMX (indeterminada)» no traen coordenadas, así que se conservan para el total de la ciudad con la clave 09000.
4. **Duplicados.** El archivo no trae un identificador de carpeta. Las 3,824 filas idénticas en las 21 columnas (0.19 %) tienen como hora de inicio 00:00:00, un valor de relleno, y son sobre todo fraude y abuso de confianza, lo que sugiere denuncias múltiples de un mismo hecho. Se *marcan* en lugar de borrarse, y el conteo agregado las excluye.
5. **Grupos de delito estables.** Los 352 delitos distintos se agrupan en 22 categorías mediante palabras clave, no por nombre exacto. Así, los cambios de denominación del catálogo de 2019 (nota de reclasificación de la FGJ) no rompen las series. Solo el 7 % queda en «otros», y las 16 categorías de alto impacto de la FGJ caen cada una en un único grupo.

Tabla 16: Pasos de limpieza de las carpetas de la FGJ.

Paso	Registros	Acción
Registros leídos (9 archivos)	1,987,424	—
Idénticos en las 21 columnas	3,824	se marcan
Sin fecha del hecho	545	se descartan
Hecho anterior a 2016	32,223	se descartan
Hecho posterior al inicio de la carpeta	110	se descartan
Hecho fuera de la CDMX	16,734	se descartan
En la CDMX sin alcaldía identificable	18,595	se conservan (clave 09000)
Hechos no delictivos	66,960	se marcan
Últimos 2 meses (subregistro)	30,814	se marcan
Base limpia	1,937,812	97.5 % del original

Salidas. `fgj_carpetas.parquet`, con una fila por carpeta, y `fgj_alcaldia_mes.parquet`, con los conteos por alcaldía, mes y grupo de delito (34,683 filas). Esta tabla incluye la clave INEGI y el nombre

de la alcaldía; las carpetas sin alcaldía identificable aparecen con la clave 09000 y el nombre «CDMX (sin alcaldía)».

Primeros resultados. La Figura 2 muestra tres grupos con comportamientos distintos:

- **Robo a transeúnte:** cayó con el confinamiento y no se ha recuperado (18,528 carpetas en 2019, 12,306 en 2020 y 10,682 en 2023). Sin embargo, *ya venía bajando desde finales de 2018*, así que no toda la caída puede atribuirse a la pandemia.
- **Violencia familiar:** bajó en abril de 2020, probablemente porque el confinamiento dificultó denunciar, y después subió con fuerza (25,802 en 2019, 28,340 en 2020 y 37,310 en 2023). Esto es consistente con la hipótesis H2.
- **Robo en transporte público:** cayó a menos de la mitad y se estabilizó en ese nivel, igual que la afluencia del Metro.




Figura 2: Carpetas mensuales por grupo de delito (sin los meses incompletos). Fuente: elaboración propia con datos de la FGJ.

6.3. Afluencia del Metrobús

Tabla 17: Pasos de limpieza del Metrobús.

Paso	Resultado
Registros leídos (fecha × línea)	53,732
Nombres de línea (Línea N / línea N en 2023)	14 → 7 unificados
Vacíos antes de la inauguración de cada línea	17,227; no son faltantes, se marcan
Faltantes con la línea operando	0
Duplicados fecha × línea	0
Días atípicos respecto a la mediana móvil de 29 días	30; se conservan (eventos reales)
Errores evidentes	2; se anulan
Valores con decimales (Línea 4, ene-feb 2025)	57; se redondean y se marcan como estimados

Valores atípicos. Se compararon con la mediana móvil de 29 días de la misma línea. Casi todos los días bajos corresponden a hechos reales: domingos, 1 de enero, el día posterior al sismo del 19-S de

2017, la jornada electoral de 2018, la visita papal de 2016 y los desfiles del 16 de septiembre. Esos se conservan. Solo se anularon dos errores evidentes:

- 26 de julio de 2005, Línea 1: 3.03 millones de viajes, unas 13 veces un día normal. Probablemente es el acumulado desde la inauguración.
- 20 de septiembre de 2017, Línea 2: 9 pasajeros.

Metro frente a Metrobús. Ambos sistemas cayeron casi lo mismo en mayo de 2020: el Metro a un índice de 26.5 y el Metrobús a 24.2, con 2019 = 100. Sin embargo, su recuperación fue muy distinta (Figura 3). El Metrobús superó su nivel de 2019 a partir de la segunda mitad de 2022 y en 2024 alcanzó un promedio anual de 118.9. El Metro, en cambio, se ha quedado entre 73 y 79 (promedios anuales de 2024 y 2025). Esto puede deberse a la ampliación de la red del Metrobús y al traslado de usuarios por los cierres de las Líneas 1 y 12 del Metro. Es una pregunta que conviene responder en la fase de análisis.




Figura 3: Afluencia diaria promedio mensual del Metro y del Metrobús, índice 2019 = 100. Fuente: elaboración propia con datos del STC Metro y del Metrobús.

6.4. Puestos de trabajo asegurados (IMSS)

La limpieza del IMSS se hizo paso a paso en el notebook `01_limpieza_datasets.ipynb`. El resultado, `imss_subdelegacion_mes.csv`, tiene una fila por mes y subdelegación del IMSS: 128 meses por 10 subdelegaciones, es decir, 1,280 filas.

Decisiones.

- **Medida de empleo:** se usan los *puestos de trabajo* (`ta`) y no los *asegurados*, que incluyen a personas afiliadas sin empleo. En la CDMX hay unos 5 millones de asegurados, pero solo unos 3.5 millones de puestos.
- **Territorio:** el IMSS no publica la CDMX por alcaldía. Las delegaciones (Norte y Sur) y las subdelegaciones son oficinas del IMSS, y los empleos se registran donde la empresa dio de alta su registro patronal. Por eso solo se usan como dato complementario.
- **Columnas cambiantes:** el IMSS agregó `rango_uma` en febrero de 2017 y `ptpd` en 2026, y en 7 meses publicó un nombre de columna mal codificado. El código lee solo las columnas necesarias, con el nombre que tengan en cada archivo.
- **Vacíos en el rango salarial:** el 99.7 % corresponde a asegurados sin empleo, que no tienen salario, así que no se imputan. Los puestos sin rango (menos del 0.5 %) van a una categoría «sin dato».

- **Rango de UMA en 2016:** se copió el rango en salarios mínimos, porque en 2016 la UMA valía lo mismo que el salario mínimo (\$73.04). Enero de 2017 queda aproximado.

Validación. No faltan meses. Hombres, mujeres y no binario suman exactamente los puestos, y los rangos salariales también. Diciembre de 2019 coincide con la cifra calculada directamente del archivo original (3,470,048 puestos).

Tabla 18: Puestos de trabajo formales en la CDMX (IMSS).

Mes	Puestos	Mujeres	Salario diario (nominal)
Diciembre 2019	3,470,048	1,447,069	\$471
Diciembre 2020	3,246,669	1,347,572	\$510
Marzo 2021 (mínimo)	3,213,626	1,338,652	\$539
Diciembre 2024	3,479,354	1,518,611	\$729
Agosto 2026	3,689,815	1,585,251	\$801

Primeros resultados. Entre febrero y diciembre de 2020 se perdieron unos 200 mil empleos formales, y el punto más bajo llegó en marzo de 2021, con unos 233 mil puestos menos que en febrero de 2020. El promedio anual volvió a 99.6 (2019 = 100) en 2023 y a 101.2 en 2024. El empleo formal se recuperó mucho antes que la afluencia del Metro, que sigue entre 73 y 79, lo cual apoya la hipótesis H3.

Advertencia sobre los rangos salariales. El grupo «hasta 2 UMA» pasa de 1.17 millones de puestos en 2019 a 21 mil en 2024. No es un error: el salario mínimo subió hasta equivaler a unas 2.3 UMA, así que ya nadie puede ganar legalmente menos de 2 UMA. Por eso, para comparar salarios antes y después de la pandemia se usará el salario promedio *deflactado* con el INPC. El salario nominal subió 55 % entre 2019 y 2024, con una inflación cercana al 30 %.

Gráficas. La Figura 4 muestra las cinco subdelegaciones con más empleo formal. Polanco concentra cerca de 700 mil puestos porque ahí registran su plantilla muchas empresas grandes, no porque ahí trabaje toda esa gente. Desde finales de 2025, San Ángel presenta saltos de hasta ± 60 mil puestos de un mes a otro, que no aparecen en el total de la ciudad. Probablemente se deben a reasignaciones administrativas de registros patronales entre subdelegaciones, así que no deben interpretarse como cambios de empleo.

La Figura 5 muestra la distribución por rango salarial. Hay dos caídas abruptas del grupo «hasta 2 UMA», en enero de 2022 (a 0.3 %, y en febrero regresa a 22 %) y en enero de 2023 (definitiva). Se explican por el calendario: el salario mínimo sube el 1 de enero y la UMA hasta el 1 de febrero. En enero de 2022, el salario mínimo integrado ($\approx \$180.7$) quedó apenas por encima de 2 UMA de 2021 ($\$179.24$); en febrero, con la UMA nueva, volvió a quedar por debajo. Desde 2023 el mínimo supera las 2 UMA de forma permanente. Es un efecto de la política salarial y no un error de los datos.

6.5. Ocupación hotelera

La serie mensual del porcentaje de ocupación hotelera (octubre de 2018 a julio de 2024) no tiene vacíos, meses faltantes, duplicados ni valores fuera del rango 0–100 %. Los valores de abril a junio de 2020 (1.6 a 3.4 %) son reales, porque corresponden al confinamiento, y se conservan. La limpieza, hecha en el notebook 01, consistió en tres pasos:




Figura 4: Puestos de trabajo formales en las cinco subdelegaciones del IMSS con más empleo en 2019.

1. **Redondeo a dos decimales.** 47 de los 70 valores, entre febrero de 2020 y abril de 2024, traían más de dos decimales. Los demás traían dos. Esto sugiere que la fuente cambió su forma de calcular el dato al inicio de la pandemia.
2. **Fecha al primer día del mes,** en lugar del último, para poder unirla con las demás fuentes.
3. **Nombre de columna** `ocupacion_pct`.

El resultado se guardó en `data/interim/hoteles_mes.csv`. La ocupación promedio fue de 67.7 % en 2019. Bajó a 1.55 % en mayo de 2020 y en 2023 fue de 63.6 %, es decir, unos 4 puntos por debajo del nivel previo a la pandemia. Queda pendiente estimar 2016 a septiembre de 2018 con *backcasting*, en el paso de completar (Figura 7).

6.6. Hechos de tránsito

Se unieron la serie ampliada (2018–2023) y la de 2024, y se construyó una tabla con el número de accidentes por mes, alcaldía y tipo, junto con las personas lesionadas y fallecidas. Son 8,064 filas: 84 meses por 16 alcaldías por 6 tipos. Las combinaciones sin accidentes se registran como 0, porque no son datos faltantes. El notebook 01 incluye al final de la sección una tabla con todos los errores encontrados, los registros afectados y la decisión tomada. Los principales fueron:

- **Formatos distintos** de fecha (aaaa-mm-dd frente a dd/mm/aaaa) y de hora entre los dos archivos.
- **Folio «SD»** (sin dato) en 7,288 registros, casi todos de 2018. Los folios repetidos corresponden a accidentes distintos, así que se contaron filas y no folios.
- **28 duplicados reales**, con la misma fecha, hora, tipo y coordenadas. Se eliminaron.
- **Nombres de alcaldía no estándar**, como «GUSTAVO A MADERO», «CUAJIMALPA» o la errata «CUAHUTEMOC», y una avenida registrada como alcaldía («AV INSURGENTES»). Se unificaron a la clave INEGI; la avenida se asignó por coordenadas.
- **El nombre de la alcaldía coincide con las coordenadas en el 95.8 % de los casos**, frente al 99.7 % de la FGJ. Se conservó la alcaldía del registro. La diferencia probablemente se debe a accidentes en los límites entre alcaldías.

Tabla diaria. Por si el análisis la requiere, se generó también `transito_alcaldia_dia`, con los mismos accidentes por día, alcaldía y tipo: 245,472 filas (2,557 días por 16 alcaldías por 6 tipos). Sus sumas coinciden mes por mes con la tabla mensual. No falta ningún día, pero siete días tienen




Figura 5: Distribución de los puestos de trabajo por rango salarial en UMA, CDMX.

Tabla 19: Hechos de tránsito por año (164,706 accidentes).

Año	Choque	Atropellado	Caída de ciclista	Total	Fallecidos
2018	9,608	4,297	156	17,025	394
2019	8,471	5,086	133	18,014	397
2020	9,251	2,761	544	16,440	388
2021	13,445	3,468	762	22,855	424
2022	18,523	4,676	845	30,702	533
2023	17,593	4,552	711	29,020	472
2024	18,109	4,821	760	30,650	533

menos del 40 % de los registros normales según la mediana móvil de 29 días. Por ejemplo, el 7 de mayo de 2018 tiene 4 accidentes y el 26 de junio de 2023 tiene 10, cuando lo normal es alrededor de 30 y 80. Probablemente son días con registro incompleto: se conservan y se marcan con la columna `registro\bajo`.

Problemas detectados al graficar. Las gráficas revelaron dos cortes de registro que no se veían en las tablas, y que se agregaron a la tabla de errores del notebook:

- **Caídas de ciclista:** pasan de unas 11 a unas 65 al mes en *febrero de 2020*, antes del confinamiento. Un salto tan brusco y previo a la pandemia indica un cambio en la forma de registrar este tipo de accidente, no un aumento de ciclistas. Por eso no se usa para comparar antes y después.
- **Primer semestre de 2018:** los atropellados son la mitad que en el segundo semestre (unos 230 contra 450 al mes), y en 2018 el 43 % de los registros no tiene folio. El registro parece incompleto, así que la línea base de esta fuente es 2019.

Primeros resultados. Los **atropellados** son el indicador más confiable de esta fuente. Cayeron un 68 % en abril–mayo de 2020 (134 al mes, frente a 424 en 2019) y en 2024 volvieron al 95 % del nivel de 2019 (Figura 9). Por alcaldía (Figura 10), la caída de 2020 fue mayor en las alcaldías centrales y de oficinas que en las periféricas y populares:

- Centrales: Coyoacán 38, Miguel Hidalgo 43, Cuauhtémoc 45 y Benito Juárez 48 (2019 = 100).
- Periféricas: Iztapalapa 63, Gustavo A. Madero 68 e Iztacalco 68.




Figura 6: Salario diario promedio (pesos corrientes) por subdelegación y promedio de la CDMX.




Figura 7: Ocupación hotelera mensual en la CDMX. La línea punteada es el promedio de 2019.

- Excepciones: Milpa Alta, periférica, cayó tanto como las centrales (43), y Venustiano Carranza, central, cayó poco (68). Milpa Alta tiene pocos atropellados al año, así que su índice varía mucho. Esto es coherente con la hipótesis H4: donde más gente pudo trabajar desde casa, menos personas salieron a la calle. Las muertes en hechos de tránsito se mantuvieron en unas 395 al año entre 2018 y 2020 y subieron hasta 533 en 2022 y 2024 (Figura 11). El aumento se concentra en los derrapados, típicamente de motocicleta (de 33 a 106), aunque parte puede deberse al cambio de registro.

6.7. Afluencia del Metro

La limpieza se hizo por pasos en el notebook 01, a partir de `afluencia_metro_simple.csv` (1,180,920 registros: 195 estaciones por día entre enero de 2010 y julio de 2026). La versión desglosada por tipo de pago solo existe desde 2021 y suma exactamente lo mismo día por día, así que no se usó. No hay celdas vacías, días faltantes ni valores negativos; los problemas estaban en los nombres y en el significado de los ceros (Tabla 20).




Figura 8: Hechos de tránsito mensuales por tipo. El salto de 2021–2022 se debe en parte al cambio de registro.

Tabla 20: Errores encontrados en la limpieza del Metro.

Error	Registros	Decisión
Línea escrita <i>LÃÑnea</i> N (2021–2023) y <i>Linea</i> N (resto)	171,795	Se repara y se unifica a <i>LÃÑnea</i> N (24 → 12)
Nombre de estación con <i>mojibake</i> (<i>CatÃğlica</i>)	379,245	Se repara con <i>ftfy</i>
Gómez Farias / Peñón viejo (desde 2023-06)	2,314	Se unifican a la escritura anterior
Línea B, dic-2020: «Oceanía» dos veces por día y falta «Deportivo Oceanía»	31	El 2.º registro se reasigna a Deportivo Oceanía
Ceros de la Línea 12 antes de su inauguración	20,780	Vacío; estado <i>no_existia</i>
Sistema completo en ≈0 (servicio gratuito: 16–17 mar 2016 y 20–27 sep 2017)	1,950	Vacío; estado <i>sin_registro</i>
Estación cerrada (COVID, obras de L1 y L12, incendio del PCC)	39,667	Es un 0 real; estado <i>cerrada</i>
Días > 4 veces la mediana móvil de 29 días	90	Se conservan (12 de diciembre, conciertos, reaperturas)

Duplicado de Oceanía. En diciembre de 2020 la estación Oceanía de la Línea B aparece dos veces por día y Deportivo Oceanía no aparece. El primer registro promedia 5,307 viajes, parecido a Oceanía en noviembre (5,625), y el segundo 7,054, parecido a Deportivo Oceanía (7,310). Además, el segundo ocupa en el archivo el lugar de Deportivo Oceanía en el orden de la línea. Por eso se trató como un error de etiqueta y se reasignó en lugar de borrarse.

Tres tipos de ceros. Un cero puede significar que la estación no existía, que el Metro funcionó sin contar pasajeros o que la estación estuvo cerrada. Solo el último es un cero real. Los días sin conteo se detectaron porque el total de todo el sistema fue menor al 10 % de su mediana móvil. Coinciden con el servicio gratuito posterior al sismo del 19-S y con la contingencia ambiental de marzo de 2016. Se dejaron vacíos para no simular que nadie usó el Metro, y los promedios mensuales se calculan solo con los días que tienen dato.




Figura 9: Atropellados y caídas de ciclista por mes. Obsérvese el corte de registro de febrero de 2020 en las caídas de ciclista.

Salidas. La tabla por estación y día supera el límite de filas de Excel, así que se guardaron tres agregados en CSV y Parquet: `metro_linea_dia` (71,633 filas), `metro_estacion_mes` (38,125) y `metro_mes` (199 meses, con el total, los días con dato, las estaciones cerradas en promedio y una columna por línea). Los totales de las tres tablas coinciden con los de la base depurada (23,155 millones de viajes).

Cierres de líneas. La Línea 12 estuvo cerrada por completo desde el colapso del 3 de mayo de 2021, reabrió por tramos desde enero de 2023 y por completo en enero de 2024. La Línea 1 cerró 12 estaciones por modernización desde julio de 2022 y reabrió por etapas hasta diciembre de 2025 (Figura 14). Estos cierres quedan marcados en los datos para no confundirlos con la falta de recuperación de la demanda.

Primeros resultados. En mayo de 2020 la afluencia diaria fue el 26 % de la de 2019, y el promedio de 2020 fue el 56 %, lo que apoya la hipótesis H1 (Figura 12). En 2025 el Metro llegó al 79 % de 2019. Sin las Líneas 1 y 12 llega al 83 %: los cierres por obra explican solo una parte de la diferencia y la demanda todavía no ha vuelto. La recuperación también es desigual entre líneas (Figura 13). En 2025 las Líneas A, 9, 8, 12 y 4 están entre 87 y 96, y las Líneas 2, 3, 5, 6, 7 y B entre 73 y 82. La Línea 1, todavía en obras buena parte del año, llegó a 51.

6.8. Casos positivos de COVID-19

Es la variable de control que mide la intensidad de la pandemia. El archivo tiene una fila por día de toma de muestra entre el 5 de marzo de 2020 y el 8 de abril de 2023, con pruebas y positivos del total de personas atendidas y de los residentes de la CDMX. Se usan los de residentes. No tiene celdas vacías, y las tasas de positividad del archivo están bien calculadas. La limpieza se hizo en el notebook 01 (Tabla 21).




Figura 10: Atropellados por alcaldía, índice 2019 = 100. Los valores de 2018 están subestimados por registro incompleto.

Salidas. `covid_dia` (1,130 días), `covid_semana` (162 semanas, con la misma semana ISO que el semáforo para poder unirlos) y `covid_mes` (38 meses). Las tasas semanales y mensuales se calculan con las sumas del periodo, no como promedio de tasas diarias. La primera y la última semana y el primer y el último mes están incompletos y se marcan. Después de abril de 2023 no hay dato: al integrar se debe dejar vacío, no en 0.

Primeros resultados. Se observan cuatro olas grandes (Figura 15): la de invierno 2020–2021 (unos 33 mil positivos por semana), Delta (23 mil), Ómicron, que es el máximo de la serie con casi 60 mil en la tercera semana de 2022, y BA.5 a mitad de 2022 (46 mil). La positividad llegó al 45 % a mitad de 2020, al 46 % con Ómicron y al 59 % con BA.5, así que en esos momentos muchos contagios no se detectaban. Por eso, como control, conviene usar la tasa de positividad junto con los positivos.

6.9. Semáforo epidemiológico

Es la segunda variable de control: indica qué restricciones estaban vigentes cada semana. El archivo viene en formato ancho, con una fila por entidad y una columna por semana ISO. La limpieza, hecha en el notebook 01, consistió en cuatro pasos:

1. **Filtrar la CDMX** y pasar a formato largo, con una fila por semana.
2. **Fecha de la semana:** el lunes de cada semana ISO, igual que en `covid_semana`, para poder unir las dos fuentes.
3. **Semanas faltantes.** La revisión con `isna()` no encontró vacíos, pero al comparar contra el calendario completo faltaban dos semanas: 2020-W53 (2020 tuvo 53 semanas ISO) y 2022-W01.
4. **Relleno.** En ambos casos la semana anterior y la siguiente tienen el mismo color (rojo y verde,




Figura 11: Personas fallecidas en hechos de tránsito por año y tipo de accidente.




Figura 12: Afluencia diaria promedio mensual del Metro, completo y sin las Líneas 1 y 12. Las bandas marcan los periodos de choque, transición y post-pandemia.

respectivamente), así que se rellenaron con ese color y se marcaron con la columna `imputado`. Si los colores vecinos hubieran sido distintos, no se habría rellenado.

El resultado, `semaforo_cdmx_semana.csv`, tiene 160 semanas, de 2020-W22 a 2023-W24: 15 en rojo, 42 en naranja, 20 en amarillo y 83 en verde.

7. Plan de trabajo y actividades pendientes

7.1. Preparación

- ✓ Definir la pregunta y el problema.
- ✓ Identificar las fuentes de información.
- ✓ Crear el entorno de Python (`.venv`) y el notebook de contexto (`notebooks/00_contexto_y_datasets.ipynb`).
- ❑ Completar la estructura de carpetas (`src/`, `docs/`, `data/interim/`, `data/processed/`).
- ❑ Crear el control de versiones y el archivo `data/raw/MANIFEST.csv`.
- ❑ Confirmar los cortes de los periodos de análisis.




Figura 13: Afluencia diaria promedio por línea y año, índice 2019 = 100.

Tabla 21: Errores encontrados en la limpieza de los casos COVID.

Error	Registros	Decisión
Días de marzo de 2020 sin fila (sin muestras tomadas)	17	Se agregan con 0 y se marcan
Antes del 5-abr-2020, menos de 70 pruebas por día (arranque del registro)	31	Se conservan y se marcan
29-mar-2020: positivos de residentes (6) mayores que el total (5)	1	Se sube el total a 6
Fines de semana con muchas menos pruebas (el domingo, unas 4 veces menos que entre semana)	323	No es error: promedio móvil de 7 días y análisis semanal

7.2. Descarga (14 conjuntos seleccionados)

- ✓ Seleccionar los conjuntos de datos (Tabla 5).
- ✓ Scripts de descarga con MANIFEST (Sección 5).
- ✓ Movilidad: Metro, Metrobús, Ecobici, hechos de tránsito (comparable, ampliada y 2024).
- ✓ Seguridad: carpetas FGJ 2016–2024, llamadas al 911 2019–2022.
- ❑ Seguridad: SESNSP municipal (descarga manual).
- ✓ Economía: DENUE, ocupación hotelera, ENOE (35 trimestres), IMSS (128 meses).
- ✓ Pandemia y referencia: casos COVID, semáforo federal, Censo 2020, Marco Geoestadístico.

7.3. Tareas surgidas en la descarga

- ❑ Unificar los formatos de fecha del 911 y revisar los traslapes entre semestres.
- ❑ Documentar el cambio de registro de los hechos de tránsito (2021–2022).
- ❑ Fijar la ventana post-pandemia común (2023-01 – 2024-07).
- ✓ Rellenar las semanas 2020-W53 y 2022-W01 del semáforo.




Figura 14: Estaciones del Metro cerradas por día. El pico de enero de 2021 corresponde al incendio del Puesto Central de Control.

7.4. Exploración

- ☐ Obtener el perfil de cada conjunto: filas, columnas, rango de fechas, % de nulos, tipos y categorías.
- ☐ Documentar los cambios metodológicos de cada fuente.

7.5. Limpieza (selección final)

- ✓ Catálogo de alcaldías (clave INEGI y polígonos) y normalización de texto.
- ✓ Carpetas FGJ, Metrobús e IMSS.
- ✓ Metro: codificación, nombres, duplicados, tipos de ceros y cierres de las Líneas 1 y 12 marcados.
- ☐ Metro: usar en la integración el promedio diario y una variante sin las Líneas 1 y 12.
- ✓ Semáforo: rellenar 2020-W53 y 2022-W01 (mismo color que las semanas vecinas, marcadas con imputado).
- ✓ Hechos de tránsito (mensual y diario), ocupación hotelera y casos COVID (diario, semanal y mensual).
- ☐ Ocupación hotelera: *backcasting* 2016–2018.
- ☐ Población por alcaldía (Censo 2020) para calcular tasas.

7.6. Integración y entrega

- ☐ Construir las bases `cdmx\_mensual\_alcaldia` y `cdmx\_semanal`.
- ☐ Calcular las tasas y los índices, y añadir las variables de periodo y semáforo.
- ☐ Validar contra las cifras oficiales y elaborar el diccionario de datos.
- ☐ Hacer un análisis descriptivo con gráficas antes, durante y después de la pandemia.

A. Enlaces a las fuentes

Movilidad

- Metro: <https://datos.cdmx.gob.mx/dataset/afluencia-diaria-del-metro-cdmx>
- Metrobús: <https://datos.cdmx.gob.mx/dataset/afluencia-diaria-de-metrobus-cdmx>
- STE: <https://datos.cdmx.gob.mx/dataset/afluencia-diaria-servicio-de-transportes-electricos>
- RTP: <https://datos.cdmx.gob.mx/dataset/afluencia-diaria-de-la-red-de-transporte-de-pasajeros>




Figura 15: Casos positivos de COVID-19 por semana y tasa de positividad (residentes de la CDMX).

- Afluencia preliminar: <https://datos.cdmx.gob.mx/dataset/afluencia-preliminar-en-transporte-publico>
- Ecobici: <https://datos.cdmx.gob.mx/dataset/afluencia-diaria-del-sistema-ecobici>
- Movilidad histórico COVID-19: <https://datos.cdmx.gob.mx/dataset/movilidad-historico-covid-19>
- Hechos de tránsito SSC: <https://datos.cdmx.gob.mx/dataset/hechos-de-transito-reportados-por-scs-base-comparativa>
- Hechos de tránsito usados en el proyecto (Google Drive): https://drive.google.com/drive/folders/1_Ih0f-9izLZPIRkHpHvWx10ML001kmAK
- Google Mobility: <https://www.google.com/covid19/mobility/>
- GTFS: <https://datos.cdmx.gob.mx/dataset/gtfs>

Seguridad

- Carpetas FGJ: <https://datos.cdmx.gob.mx/dataset/carpetas-de-investigacion-fgj-de-la-ciudad-de-mexico>
- Víctimas FGJ: <https://datos.cdmx.gob.mx/dataset/victimas-en-carpetas-de-investigacion-fgj>
- Llamadas 911: <https://datos.cdmx.gob.mx/dataset/llamadas-numero-de-atencion-a-emergencias-911>
- SESNSP: <https://www.gob.mx/sesnsp/acciones-y-programas/datos-abiertos-de-incidencia-delictiva>
- ENSU: <https://www.inegi.org.mx/programas/ensu/>
- ENVIPE: <https://www.inegi.org.mx/programas/envipe/>

Actividad económica

- IMSS: <http://datos.imss.gob.mx/>
- ENOE: <https://www.inegi.org.mx/programas/enoe/15ymas/>
- ITAEE: <https://www.inegi.org.mx/temas/itaee/>
- DENU: <https://www.inegi.org.mx/app/descarga/?ti=6>

- Directorio de unidades económicas: <https://datos.cdmx.gob.mx/dataset/directorio-estadistico-de-unidades-economicas-ciudad-de-mexico>
- Seguro de desempleo: <https://datos.cdmx.gob.mx/dataset/solicitudes-seguro-de-desempleo>
- Ocupación hotelera: <https://datos.cdmx.gob.mx/dataset/ocupacion-hotelera-en-la-ciudad-de-mexico>
- Monitor Estadístico: <https://datos.cdmx.gob.mx/dataset/indicadores-monitor-estadistico-de-la-ciudad-de-mexico>

Pandemia

- Casos y positividad: <https://datos.cdmx.gob.mx/dataset/total-de-pruebas-total-de-positivos-y-tasa-de-positividad>
- SINAVE: <https://datos.cdmx.gob.mx/dataset/base-covid-sinave>
- Casos por colonia: <https://datos.cdmx.gob.mx/dataset/covid-19-sinave-ciudad-de-mexico-a-nivel-colonia>
- Capacidad hospitalaria: <https://datos.cdmx.gob.mx/dataset/capacidad-hospitalaria>
- Semáforo: <https://covid19.cdmx.gob.mx/>
- Secretaría de Salud: <https://www.gob.mx/salud/documentos/datos-abiertos-152127>